

Generative Jazz Musik

Projekt-Poster (Gruppe A)

Alexandra Schnakenberg Fabian Manger Peer Schliephacke
Grundlagen der KI Technische Hochschule Mittelhessen WiSe 2022/2023

I BESCHREIBUNG

Das darliegende Projekt verwendet ein künstliches Neuronales Netz zur Generierung von kurzen musikalischen Phrasologien, die im Jazz-Bereich als *Licks* bekannt sind. Derartige *Jazz-Licks* erstrecken sich üblicherweise über eine kurze Anzahl an Takten und liegen einer festgelegten Kadenz zugrunde. Im Rahmen unseres Projekts wurden 3-taktige *Jazz-Licks* über eine II-V-I Verbindung in Bb-Dur generiert. Das Projekt schließt dabei das manuelle Sammeln, Modifizieren, Normalisieren und Digitalisieren von *Licks* aus Literatur und Internet mit ein. Entsprechend wurden die *Licks* mit der Musikbearbeitungssoftware musescore3 digitalisiert und in ein adäquates Format gebracht (MIDI-Format). Ferner wurden Funktionen zum Einlesen und Manipulieren von MIDI-Dateien implementiert, um mit den extrahierten Informationen der MIDI-Dateien ein Neuronales Netz (RNN) zu trainieren. Die Licks wurden anhand des Notenmaterials in 3 Kategorien aufgeteilt: *Alteriert*, *Diatonisch* und *beide Skalen*. Im Zuge dessen wurde 3 unabhängige Modelle trainiert, die sich lediglich durch die gefilterten Trainingsdaten unterscheiden. Ziel des Projektes beschreibt somit das Aufzeigen von generativer Kunst in Form von kurzen musikalischen Jazz-Phrasen durch Neuronale Netze. Daran anknüpfend wird der Fragestellung nachgegangen, ob derartig generierte *Licks* von Menschen-geschaffenen *Licks* unterscheidbar und wohlklingend sind.

II MODELL

Da Musik durchaus als Sequenz von Symbolen (Noten) beschrieben werden kann, wurde zum Generieren ein sogenanntes LSTM genutzt, das ferner einem Subtypus von rekurrenten Neuronalen Netzen entspricht. Da *Jazz-Licks* aus 2 Komponenten bestehen, Tonhöhen (Noten) und Rhythmus, besitzt das Netzwerk 2 Eingaben. Diese Eingaben werden anschließend zusammengefasst und durch 2 LSTM-Schichten geführt. Daran anknüpfend wurde ein Attention-Mechanismus implementiert und auf Grundlage einer vorhergehenden Note, die bestpassendste Note vorherzusagen. Dieser setzt sich zunächst aus einer Dense-Schicht mit einer Outputgröße von 1 zusammen, wodurch folglich jeder verborgene Zustand in ein Skalar umgewandelt wird (*tanh-Funktion*). Daran anknüpfend wird eine *Softmax-Funktion* genutzt um aus dem Skalar-Vektor einen Gewichts-Vektor zu generieren. Letztlich wird jeder verborgene Zustand mit dem generierten Gewicht multi-

pliziert und schließlich summiert, um einen Kontextvektor zu bilden. Dieser Kontextvektor wird weiterhin mithilfe einer Dense-Schicht und einer *Softmax-Funktion* genutzt, um basierend auf einer Note die nächstwahrscheinlichste Note vorherzusagen. Als Optimierer wurde *Adam* genutzt, während der *Mini-Batch-Gradient* zum Trainieren genutzt wurde. Darüber hinaus kann das Ziehen aus der Notenverteilung bedingt randomisiert werden, um verschiedene Outputs zu generieren. Um ein mögliches Overfitting vorzubeugen wurde mit Dropout-Schichten, Early-Stop und verschiedenen Epochen trainiert.

III VALIDIERUNG

Das Projekt wurde hinsichtlich 3 Ebenen evaluiert: *Statistisch*, *Musikanalytisch* und *mit einer Variante des Turing Tests*. Statistisch wurde mithilfe eines T-Tests die Datenverteilungen hinsichtlich Rhythmus und Tonhöhe zwischen den Trainingsdaten und den generierten Daten verschiedener Epochen verglichen. Es zeigte sich, dass das Modell mit steigender Epochenanzahl *Jazz-Licks* mit einer sehr ähnlichen Varianz hinsichtlich den beiden Merkmalen erzeugt - wodurch gezeigt wird, dass das Modell entsprechende Muster aus den Trainingsdaten extrahieren konnte. Die musikanalytische Analyse zeigt mithilfe von Domänenwissen, das generierte Licks mit steigender Epochenanzahl zunehmend Jazz-spezifische Charakteristika aufweisen. Letztlich wurden mehreren Musikstudenten und Jazzmusikern eine Stichprobe an Trainingsdaten und generierten *Licks* präsentiert (Jeweils 5). Diese sollten einschätzen, ob diese *Licks* von einem Menschen oder einem Computer generiert wurden. Es zeigte sich, dass je nach Lick die Einschätzung stark variiert, da abhängig von den Licks die relative Häufigkeit an richtigen Klassifizierungen stark variiert. Unabhängig von der Einschätzung zeigt eine subjektive Bewertung, dass je nach betrachteter Gruppierung (Jazz-Musiker und klassische Musiker) die Bewertung variiert. Eine Bewertungsmetrik inform der summierten Mediane der Licks legt nahe, dass den Jazz-Musikern die generierten Licks sogar mehr zusagen, als die Trainings-Daten. Bei den klassischen Musikern war es anders herum. Dennoch erzielten Licks der generierten Gruppe die höchsten Median-Werte. Die Varianz innerhalb der Daten liegt der zufälligen Ziehung zugrunde, weshalb einige 'Seltsam' klingende Licks mit aufgenommen wurden, um den Repräsentativen Charakter der Validierung zu erhalten.